

Sistemas Baseados em Similaridade

Enunciado Prático Individual 4


José Virgílio Silva Loureiro (PG52252)

T1. Nesta tarefa carreguei no Knime os dois *datasets* usando o nodo “CSV Reader” para recolher os dados referentes à qualidade do vinho.

Para a exploração dos dados criei um metanode com o nome Exploração de Dados, onde primeiramente utilizei o nodo “Data Explorer”, de onde podemos tirar as seguintes conclusões:

- Não existem missing values;
- O atributo que apresenta um desvio-padrão maior é o “total sulfur dioxide”.
- Os atributos que apresentam maior dispersão em torno da média (Variância) são o “total sulfur dioxide” e a “free sulfur dioxide”.
- O atributo que apresenta maior Skewness e maior Kurtosis é a “chlorides”.


Seguidamente com o node “Rank correlation” consigo observar que existe grande correlação entre o “total sulfur dioxide” com o “free sulfur dioxide”, consigo ver também que existe uma correlação modesta entre o “álcool” e a “quality” e ainda que existe uma correlação negativa significativa entre o “pH” e a “fixed acidity”.




T2. A) Nesta tarefa manipulei o atributo quality do dataset com o node “String manipulation” para eliminar o “=” que estava presente na coluna e estava a mais, depois usei o node “String to number” para tornar esse atributo numérico.

quality
Number (dou...
5
5
5
6
5
5
5
7

T2.B) Nesta tarefa utilizei o node “Normalizer” para normalizar todos os atributos numéricos do dataset, dentro deste nodo utilizei a configuração da transformação linear Min-Max entre 0 e 1 tal como pedido.



T2.C) e D) Nesta tarefa utilizei o node “Auto binner” para criar 4 bins de igual frequênciam sobre o valor do atributo “citric acid”, apliquei também a opção de substituir a nova coluna de bins pela coluna antiga da feature “citric acid”.




Depois utilizei o node “Table Creator”, onde criei a tabela ao lado, com o objetivo de renomear cada Bin, o primeiro corresponde a Low, o segundo a Medium, o terceiro a High e o quarto a Very High. Depois usei também utilizei o node “Value Lockup” para substituir os respetivos Bins.

S Citric acid	S Novo Cit...
Bin 1	Low
Bin 2	Medium
Bin 3	High
Bin 4	Very high


Novo Cit... String

Low
Low
Low
Very high
Low
Low


T3.A) e B) Nesta tarefa comecei por utilizar o node “PCA” para fazer uma redução de dimensão dos dados para apenas 2 dimensões tal como pedido.




Depois, utilizando os nodes “Scatter Plot” e “2D Density Plot(Legacy)” obtive as visualizações dos dados obtidos pelo PCA.




T4. A) Nesta tarefa apliquei o node “K-means” para segmentar o dataset em 3 clusters.



TA. B) e C) Nesta tarefa comecei por utilizar os nodes “Color Manager” e “Shape Manager” para atribuir diferentes cores por qualidade de vinho e diferentes formas a cada cluster do dataset:




Depois utilizando os nodes “Scatter plot” e “Scatter Plot(JFreeChart)” respetivamente obtive os seguintes gráficos:



Onde consigo ver por exemplo que o cluster 0 tem elementos que em geral tem a feature da qualidade mais próxima de 0.

T4.D) e E) Para estas tarefas comecei por usar o node “Cluster Assigner” o qual atribuiu a cada elemento dos dados de teste um cluster baseado nos dados de aprendizagem, depois com o node “CSV write” fiz um ficheiro que aos dados de teste acrescenta-se uma coluna com os clusters respetivos que o node anterior atribuiu, o ficheiro encontra-se anexado.

T5. Nesta tarefa comecei por criar uma flow variable para definir o numero de bins criados com o “Auto-binner”, para isso usei o node “Integer Widget” e usei a seguinte configuração:



Depois criei uma flow variable para definir o numero de clusters criados com o “K-means”, para isso usei o node “Integer Widget” e usei a seguinte configuração:

Dialog - 4:44 - Integer Widget

File

Control Flow Variables Job Manager Selection

Label: Label

Description: Esta flow variable controla o numero de clusters criados pelo node K-means

Variable Name: Numero de clusters

Minimum: 0

Maximum: 100

Default Value: 3

OK Apply Cancel ?

Dialog - 4:10 - k-Means

File

K-Means Properties Flow Variables Job Manager Selection Memory Policy

nrClusters Numero de clusters

Depois criei um conjunto de flow variables para definir os nomes dos gráficos que fiz até aqui, para isso usei o node “Variable Creator”, liguei o node “Variable Creator” a cada um dos nodes que produziu os plots e usei a seguinte configuração:

Dialog - 4:46:048 - Variable Creator


Create and Define Variables Flow Variables Job Manager Selection

Type	Variable Name	Value
String	Scatter Plot PCA	Scatter Plot PCA
String	Density Plot do PCA	Density Plot do PCA(2D)
String	Scatter Plot Matriz com clusters	Scatter Plot Matriz com clusters e cor para
String	Scatter Plot com clusters e cor p	Scatter Plot com clusters e cor para qualida
String	Scatter Plot com formas por clus	Scatter Plot com formas por cluster e cor p


+ Add

OK Apply Cancel ?

T6. Nesta tarefa juntei todos os nodes que produziram graficos até aqui num só componente que os mostrara juntos:



T7. Nesta tarefa comecei por testar resultados com o node “K-medoids”, para isso tive de começar por calcular as distâncias euclidianas entre os diferentes pontos dispostos em 2 dimensões, dei depois cores para o atributo de qualidade e separadamente para o atributo de cluster à semelhança do que tinha feito com o k-means e obtive as seguintes plots:



O que me fez concluir que a segmentação de dados é como esperado muito semelhante à realizada pelo node “k-means”.

De seguida experimentei também o node “Fuzzy-Means” onde separei os dados novamente por 3 clusters, tendo desta vez depois de dadas cores e visualizado agora obtido segmentações bem diferentes:

